

#### Présentation Projet 8

«Déployez un modèle dans le *cloud*»

Denis Desoubzdanne

**31 Janvier 2024** 

Formation Data Scientist

#### Sommaire

- 1. Présentation du sujet
- 2. Jeu de données et environnement local
- 3. Prise en main d'un script *PySpark*
- 4. Déploiement de la solution dans le *cloud*
- 5. Démonstration de *Databricks*
- 6. Livrables et conclusion

# 01

# Présentation du sujet

Objectif, tâches

#### Data Scientist



Start-up de l'AgriTech "Fruits!" souhaitant developper des solutions innovantes pour la récolte des fruits, dont une application mobile pour obtenir des informations des fruits à partir de leurs images photographiques



- Mon objectif : Développer un modèle de classification (images de fruits) et le déployer dans une architecture *Big Data*
- Mes tâches :
  - > S'approprier et compléter un script en PySpark pour traiter quelques images en local
  - > Définir et construire une architecture Big Data sur une plateforme cloud
  - > Démonstration de l'exécution du script et de l'architecture choisie

# 02

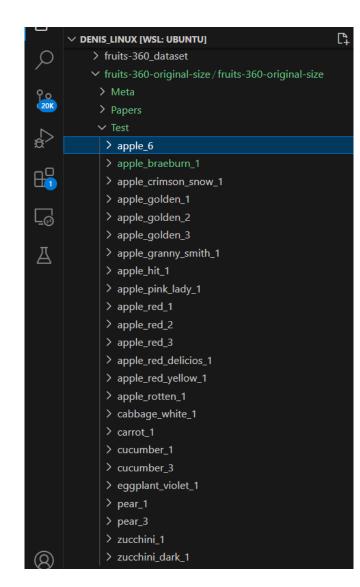
### Jeux de données & env. local

Datasets, Linux

#### Datasets

- 1 fichier 'fruits.zip' à télécharger
  - ➤ 2 dossiers : fruits-360\_dataset & fruits-360-original-size

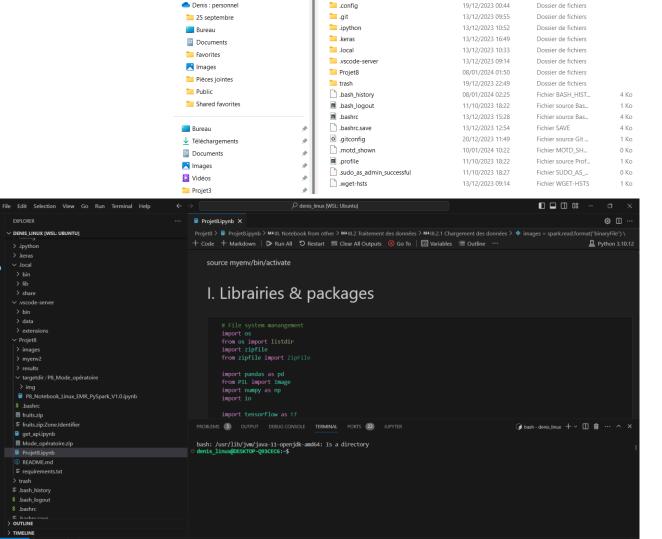
- Données utilisées : Test
  - 24 catégories de fruits/légumes : « apple », « carrot », « pear »...
  - ➤ 3110 images (< 100 Ko/image)</p>





#### Développement en local (Linux)

- Installation d'un environnement Linux sous Windows avec WSL (Windows Subsystem for Linux)
- Distribution choisie: Ubuntu
- /!\ éviter Windows, car :
  - Plus difficile de configurer PySpark
  - Plus lent
  - Problèmes de déploiement sur une plateforme cloud (Linux)



.cache

m ↑ Trier → ■ Afficher → ···

**Galerie** 

≡ fruits.zip:Zone.ldentifie

Mode opératoire.zip

get api.ipynb

③ README.md

Modifié le

19/12/2023 00:44

Taille

Dossier de fichiers

# 03

# Notebook PySpark

Utilisation d'un notebook fourni SparkSession, Transfer Learning et PCA

### Avantages de PySpark (vs Pandas)

Association Python + (Apache) Spark



- > Spark est écrit en Scala
- > API Python pour Spark
- Spark :
  - Créée en 2009 par des chercheurs de Berkeley puis vendu à Apache en 2013
  - > Framework open source pour du calcul distribué de données massives
  - Exécute la totalité des opérations d'analyse de données en mémoire et en temps réel

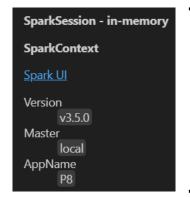


### SparkSession & calcul distribué

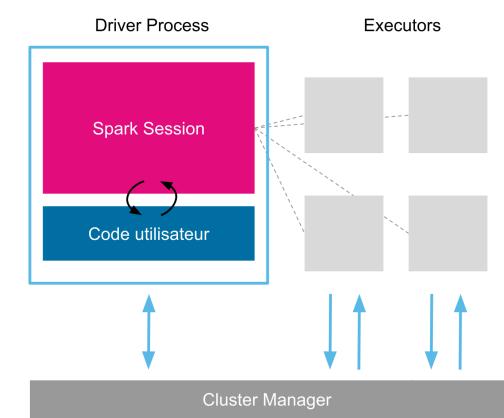
La *SparkSession est* point d'entrée permettant d'interagir avec Spark

sc = spark.sparkContext

Le SparkContext permet à l'application Spark d'accéder aux ressources du cluster et de coordonner les tâches de traitement des données.



Affichage des informations de la SparkSession en cours d'exécution



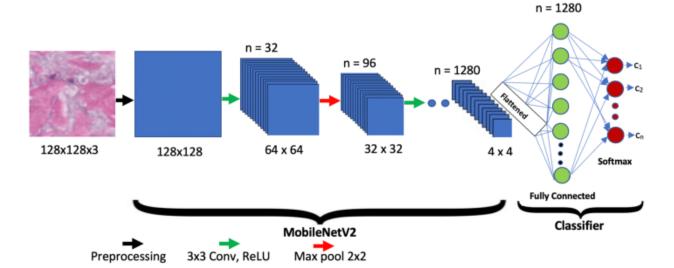
### Lecture des données images

```
images = spark.read.format("binaryFile") \
  .option("pathGlobFilter", "*.jpg") \
  .option("recursiveFileLookup", "true") \
  .load(PATH Data)
   images = images.withColumn('label', element at(split(images['path'], '/'),-2))
   print(images.printSchema())
   print(images.select('path','label').show(5,False))
root
    path: string (nullable = true)
    - modificationTime: timestamp (nullable = true)
  -- length: long (nullable = true)
  -- content: binary (nullable = true)
 |-- label: string (nullable = true)
                                                                                                                      llabel
|file:/home/denis linux/Projet8/images/fruits-360-original-size/fruits-360-original-size/Test/apple hit 1/r0 115.jpg|apple hit 1
|file:/home/denis linux/Projet8/images/fruits-360-original-size/fruits-360-original-size/Test/apple hit 1/r0 119.jpg|apple hit 1
|file:/home/denis linux/Projet8/images/fruits-360-original-size/fruits-360-original-size/Test/apple hit 1/r0 107.jpg|apple hit 1
|file:/home/denis linux/Projet8/images/fruits-360-original-size/fruits-360-original-size/Test/apple hit 1/r0 143.jpg|apple hit 1
|file:/home/denis linux/Projet8/images/fruits-360-original-size/fruits-360-original-size/Test/apple hit 1/r0 111.jpg|apple hit 1
```

- Lecture des images
- Affichage des 5 premières images (DataFrame Spark)

#### Transfer Learning: configuration du modèle

- Chargement du modèle MobileNetV2 avec les poids précalculés issus d'Imagenet
- Création d'un nouveau modèle en retirant la dernière couche (de classification) => récupération d'arrays (dim = 1280)
  - Distribution des poids du modèle à travers plusieurs nœuds (instances de traitement)



#### Transfer Learning: featuarisation

```
preprocess(content):
   Preprocesses raw image bytes for prediction.
   img = Image.open(io.BytesIO(content)).resize([224, 224])
   arr = img to array(img)
   return preprocess input(arr)
ef featurize series(model, content series):
   Featurize a pd.Series of raw images using the input model.
   :return: a pd.Series of image features
   input = np.stack(content series.map(preprocess))
   preds = model.predict(input)
   # For some layers, output features will be multi-dimensional tensors.
   # We flatten the feature tensors to vectors for easier storage in Spark DataFrames.
   output = [p.flatten() for p in preds]
   return pd.Series(output)
@pandas udf('array<float>', PandasUDFType.SCALAR ITER)
lef featurize udf(content series iter):
   This method is a Scalar Iterator pandas UDF wrapping our featurization function.
   The decorator specifies that this returns a Spark DataFrame column of type ArrayType(FloatType)
   :param content series iter: This argument is an iterator over batches of data, where each batch
                             is a pandas Series of image data.
   # With Scalar Iterator pandas UDFs, we can load the model once and then re-use it
   # for multiple data batches. This amortizes the overhead of loading big models.
   model = model fn()
   for content series in content series iter:
       yield featurize series(model, content series)
```

Prétraiter les images + transformation

Featuriser une série d'images

Itération sur l'ensemble des images

Featuarisation de l'ensemble des données fractionnées en 20 parties (tâches)

### Enregistrement au format parquet

```
features df.write.mode("overwrite").parquet(PATH Result)
2023-12-19 22:55:37.786330: I tensorflow/core/util/port.cc:113] oneDNN custom operations are on. You may see slightly different
2023-12-19 22:55:37.790019: I external/local tsl/tsl/cuda/cudart stub.cc:31] Could not find cuda drivers on your machine, GPU wil
2023-12-19 22:55:37.836343: E external/local xla/xla/stream executor/cuda/cuda dnn.cc:9261] Unable to register cuDNN factory: Att
2023-12-19 22:55:37.836424: E external/local xla/xla/stream executor/cuda/cuda fft.cc:607] Unable to register cuFFT factory: Atte
2023-12-19 22:55:37.839934: E external/local xla/xla/stream executor/cuda/cuda blas.cc:1515] Unable to register cuBLAS factory:
2023-12-19 22:55:37.849011: I external/local tsl/tsl/cuda/cudart stub.cc:31] Could not find cuda drivers on your machine, GPU wil
2023-12-19 22:55:37.849247: I tensorflow/core/platform/cpu feature guard.cc:182] This TensorFlow binary is optimized to use avail
To enable the following instructions: AVX2 AVX512F AVX512 VNNI FMA, in other operations, rebuild TensorFlow with the appropriate
2023-12-19 22:55:38.596019: W tensorflow/compiler/tf2tensorrt/utils/py utils.cc:38] TF-TRT Warning: Could not find TensorRT
     ======] - 3s 302ms/step
      (1 +
                                   - 2s 335ms/step
                                                                (2 + 1)
                                                                (3 + 1)
                                   - 2s 271ms/step
                                   - 3s 279ms/step
                                                                (4 +
                                   - 2s 305ms/step
                                                                (5 +
                                   - 2s 287ms/step
                                                                (6 +
                                   - 2s 266ms/step
                                                                (7 + 1)
```

type(features\_df)

pyspark.sql.dataframe.DataFrame

Ecriture des données en format parquet



- Stockage des données par col.
- Données compressées
- Optimisé pour les syst. distribués...

#### ACP => reduction de dimensions

```
# fct utilisateur pour convertir ArrayType en VectorUDT
def array_to_vector_udf(array_col):
    return Vectors.dense(array_col)
```

```
#enregistrement de la fct utilisateur en tant qu'UDF
array_to_vector = udf(array_to_vector_udf, VectorUDT())
features_df = features_df.withColumn('vector_features', array_to_vector('features'))
```

Conversion des données arrays en données vectorielles UDT (User-Defined Type)

/!\ Particularité des ACPs sous PySpark!!

#### features\_df.show()

path	label	features	vector_feature
file:/home/denis	apple_hit_1 [0.256	 50484, 0.313 [0	.25604841113090
file:/home/denis	apple_hit_1 [0.282	270248, 0.36 [0	.28270247578620
file:/home/denis	apple_hit_1 [0.326	698685, 0.81 [0	.32698684930801
file:/home/denis	apple_hit_1 [0.002	2047996, 0.2 [0	.00204799603670
file:/home/denis ca	bbage_white_1 [0.0,	0.6773124,   [0	.0,0.6773123741
file:/home/denis	apple_hit_1 [0.348	845182, 0.02 [0	.34845182299613
file:/home/denis	apple hit 1 [0.56	32592, 0.0, [0	.56325918436050
file:/home/denis ca	bbage_white_1 [0.0,	0.59185535, [0	.0,0.5918553471
file:/home/denis ca	bbage white 1 [0.0,	1.7062128, [0	.0,1.7062127590
file:/home/denis		217532, 0.48 [0	
file:/home/denis	apple hit 1 [0.01:	1136882, 0.0 [0	.01113688200712
file:/home/denis ca	bbage_white_1 [0.0,	0.3722937, [0	.0,0.3722937107
file:/home/denis	apple hit 1 [0.896	503764, 0.0, [0	.89603763818740
file:/home/denis	apple hit 1 [0.490	00368, 0.459 [0	.49003678560256
file:/home/denis		662186, 0.21 [0	
file:/home/denis	pear 3 [0.500	064385, 0.0, [0	.50064384937286
file:/home/denis	pear 3 [0.55]	33866, 0.026[0	.55338662862777
file:/home/denis		466481, 0.00 [0	
file:/home/denis		871104, 0.12	
file:/home/denis		1301727, 0.2	

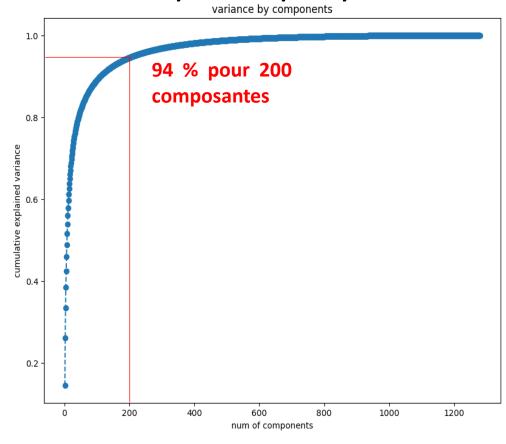
Affichage du nouveau PySpark Dataframe

#### PCA: choix du nombre de composantes

Modèle ajusté aux données pour 1280 composantes

```
pca_exp = pca_model.explainedVariance
   cumValues = pca exp.cumsum() # get the cumulative values
   cumValues[199] #selection of the 200 st components (new features)
0.9456581695702824
   # plot the graph
   plt.figure(figsize=(10,8))
   plt.plot(range(1,num elements+1), cumValues, marker = 'o', linestyle='--')
   plt.title('variance by components')
   plt.xlabel('num of components')
   plt.ylabel('cumulative explained variance')
   plt.show()
```

#### Variance expliquée cumulée en fct du nb de composantes principales



#### PCA: transformation et sauvegarde des données

```
Transformation des données sur 1280 composantes
  pca features = pca model.transform(features df)
  extract the 200 st components
 define an user fct to extract the 2 fist elts
 lef extract first n udf(features, n):
  return Vectors.dense(features[:n])
extract first n = udf(extract first n udf, VectorUDT()) #enregistrer la fct utilisateur en tant q'UDF
                                                                                            Récupération des 200 premières valeurs (composantes)
 specficy the number to extract (ex:)
n elements = 200
 appliuger l'UDF pour extraire les n premiers elts
pca features = pca features.withColumn('pca200', extract first n(col('pca features'), lit(n elements)))
                                                                                           Jointure de table pour incorporer les nouvelles features
   features df = features df.join(pca features.select('path', 'pca200'), 'path')
  # Save the DataFrame to a Parquet file
                                                                                          Ecriture des données en format parquet
  features df.write.mode("overwrite").parquet('mypca')
```

# 04

# Déploiement de la solution dans le cloud

Solution de stockage

Environnement de travail

#### Outils utilisés



	Solution	Description
3	Databricks	Plateforme d'analyse interactive
	GitHub	Plateforme de <i>versioning</i>
	Microsoft Azure	Plateforme informatique <i>Cloud</i> (solution de stockage)

#### Présentation de Databricks

Développé par les créateurs d'Apache Spark (2013)



- ➤ Plateforme web pour travailler avec Spark
- > Solution de stockage et d'analyse (ML, dashboard, SQL...)
- ➤ Fourni une gestion automatique de *clusters* et l'utilisation de *Notebooks iPython*
- Intégration aux environnements de cloud distribués
  - > Microsoft Azure





Solution choisie!

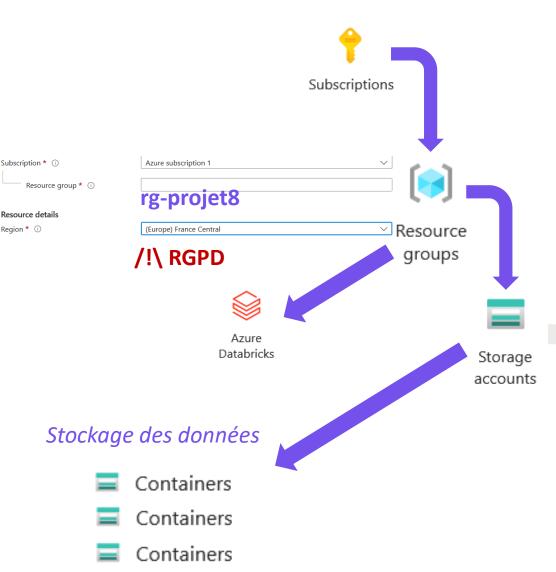
> AWS (Amazon)

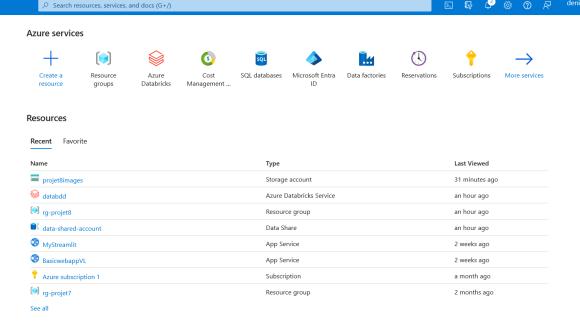


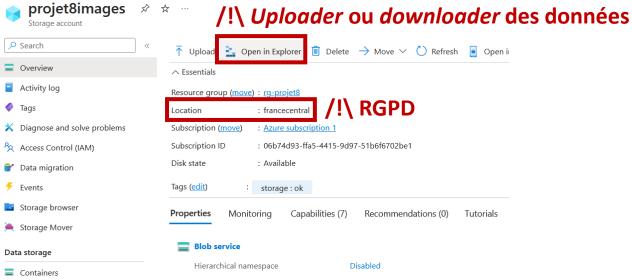
➤ Google Cloud Platform



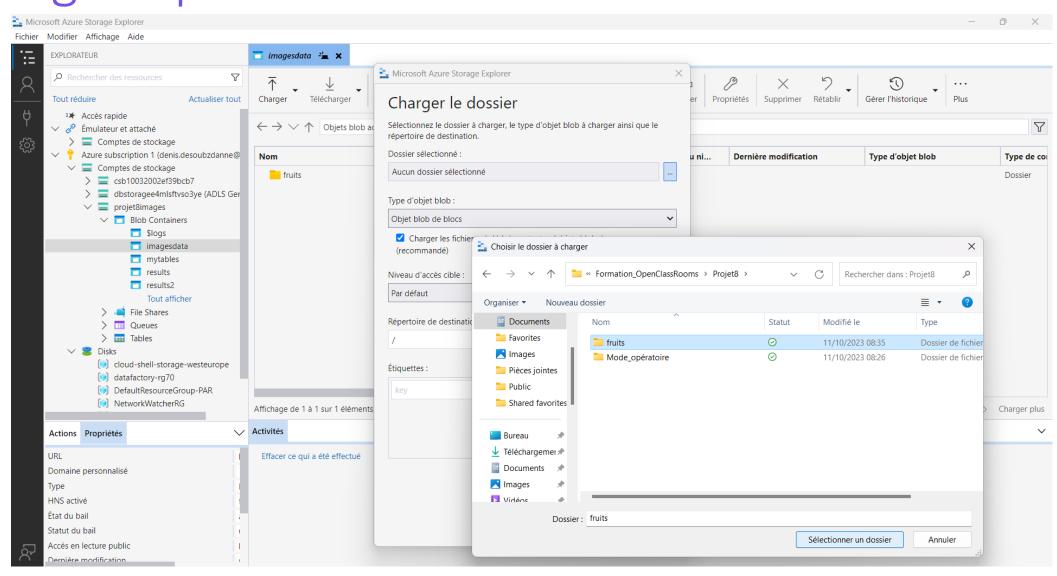
Aicrosoft Azure



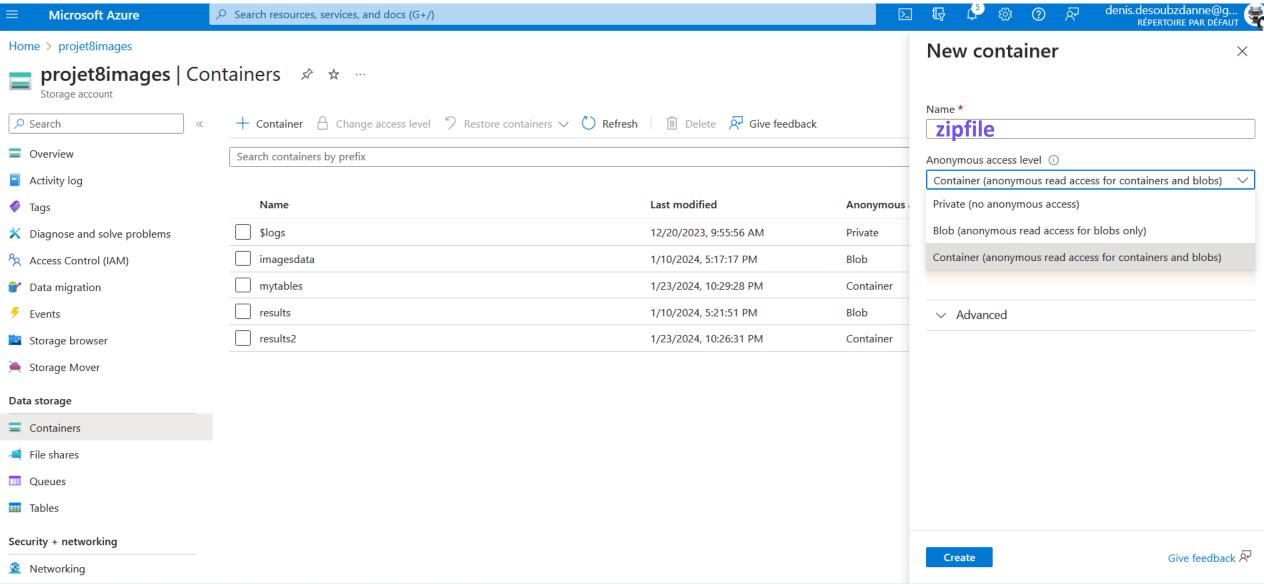




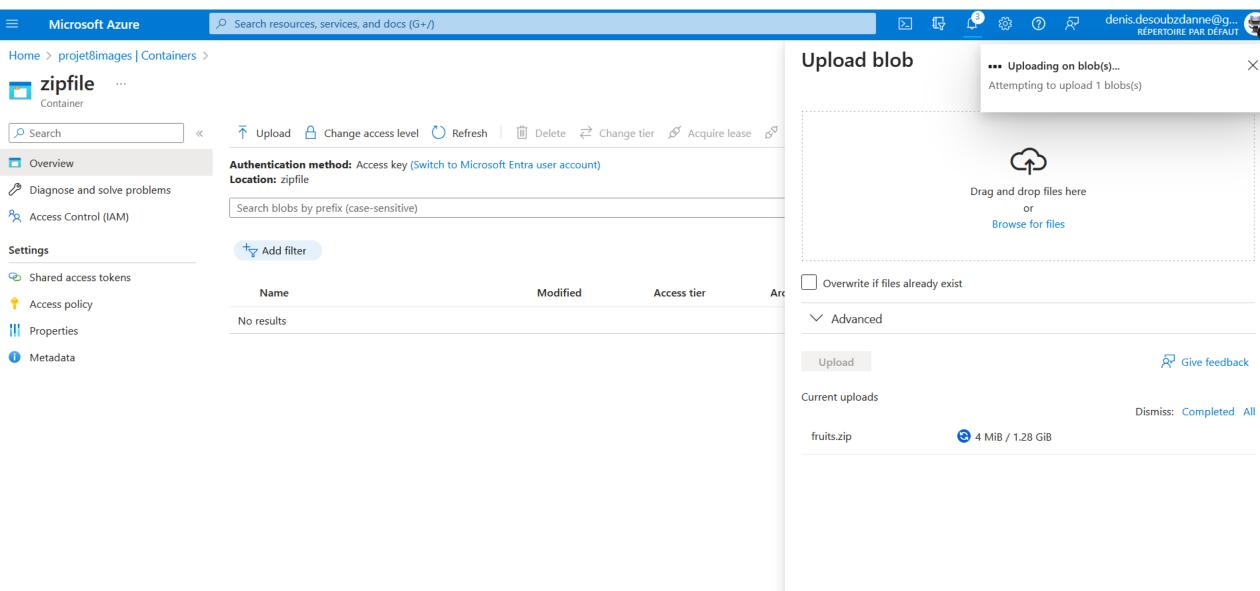
#### Stockage et accès des données *via* Azure Storage Explorer



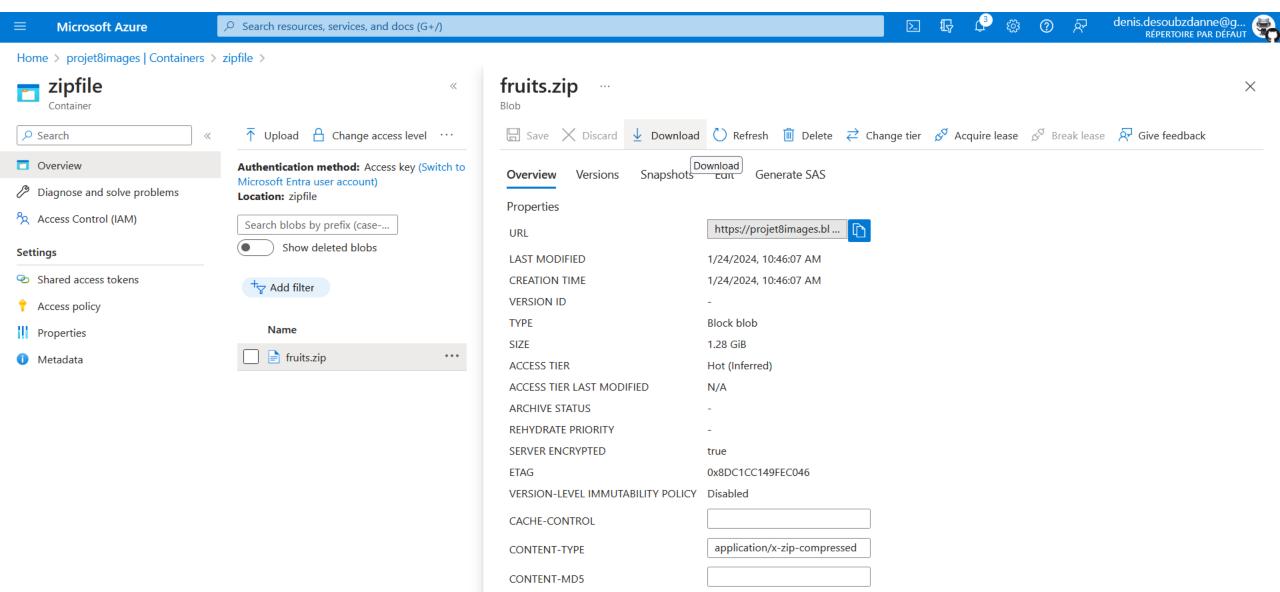
#### Creation de containers sous Microsoft Azure



#### Stockage des images dans un conteneur



#### Téléchargement des images (zip file) : lien url



#### Création d'un compte (Azure) Databricks



#### Azure services





Databricks







Management ...





Microsoft Entra









#### Resources

Recent

resource

Recent		
Name	Туре	Last Viewed
projet8images	Storage account	9 minutes ago
<b>⊗</b> databdd	Azure Databricks Service	2 hours ago
rg-projet8	Resource group	2 hours ago

#### Create an Azure Databricks workspace

#### **Project Details**

Select the subscription to manage deployed resources and costs. Use resource groups like folders to organize and manage all your resources.

Subscription * (i)	Azure subscription 1	~
Resource group * ①		~
	Create new	

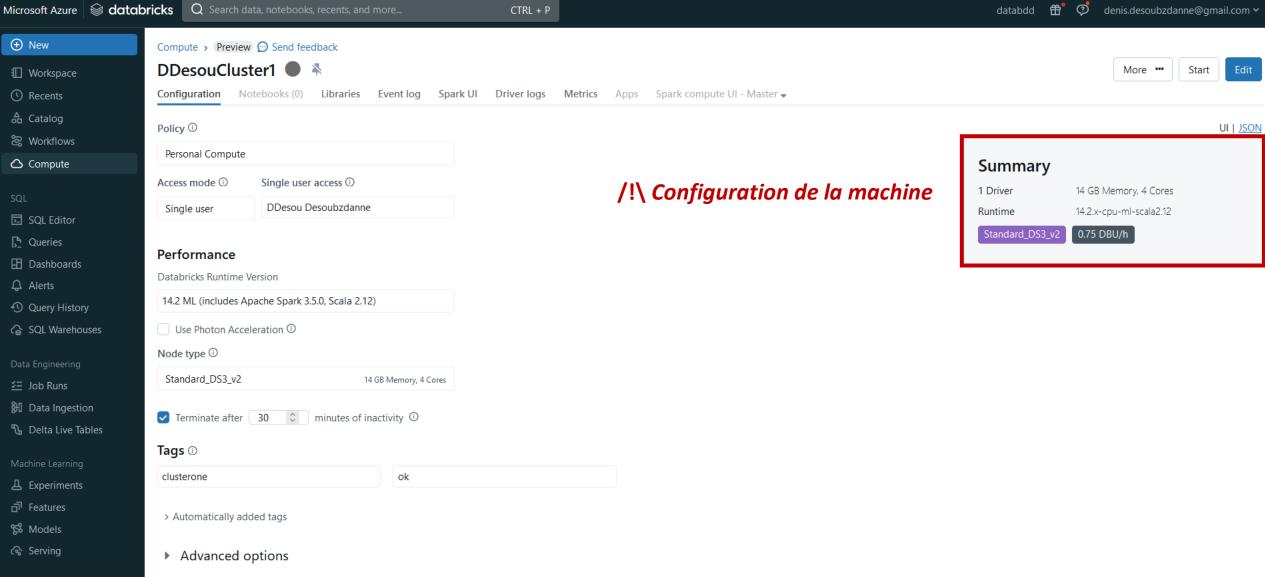
Instance Details		
Workspace name *	Enter name for Databricks workspace	
Region *	France Central	~
Pricing Tier * ①	Premium (+ Role-based access controls)	~
	We selected the recommended pricing tier for your workspace. You	×

Managed Resource Group name

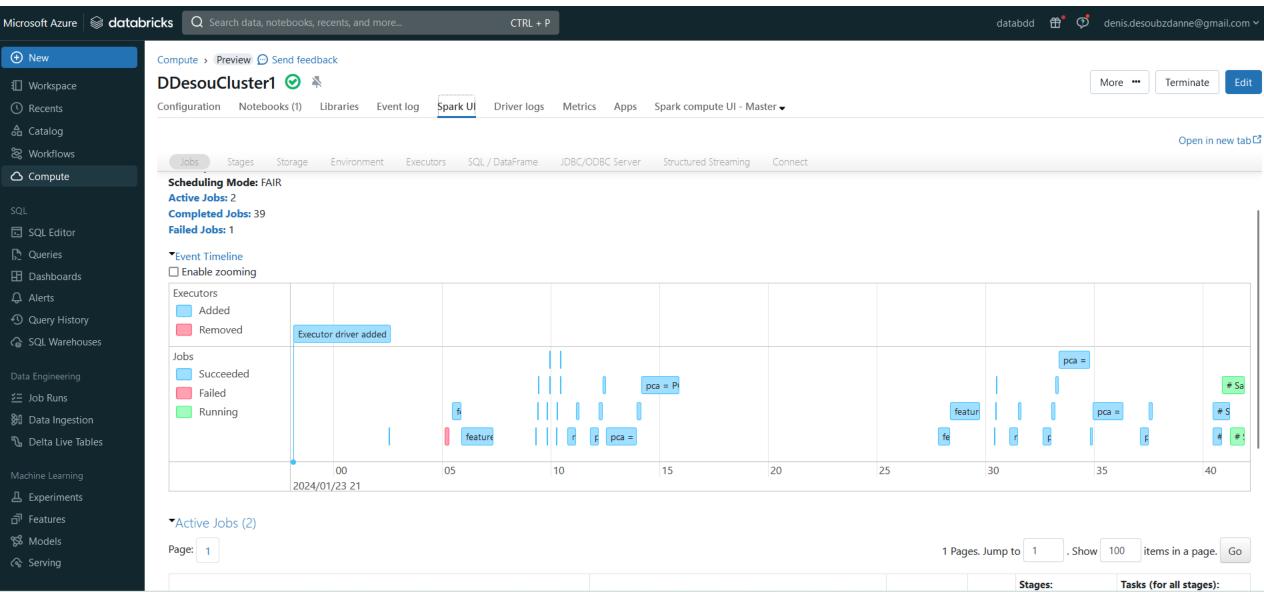
Enter name for managed resource group

can change the tier based on your needs.

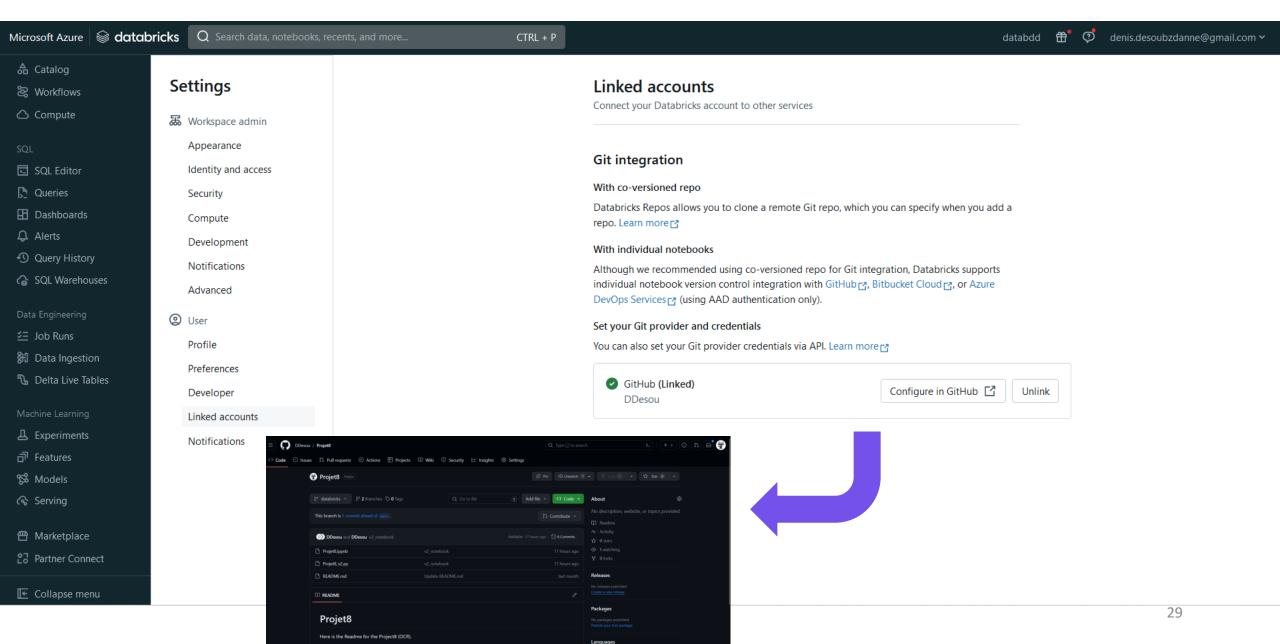
#### Mise en place d'un cluster (machine)



#### Module Spark UI (Compute)



#### Workspace connecté à un repos GitHub



# 05

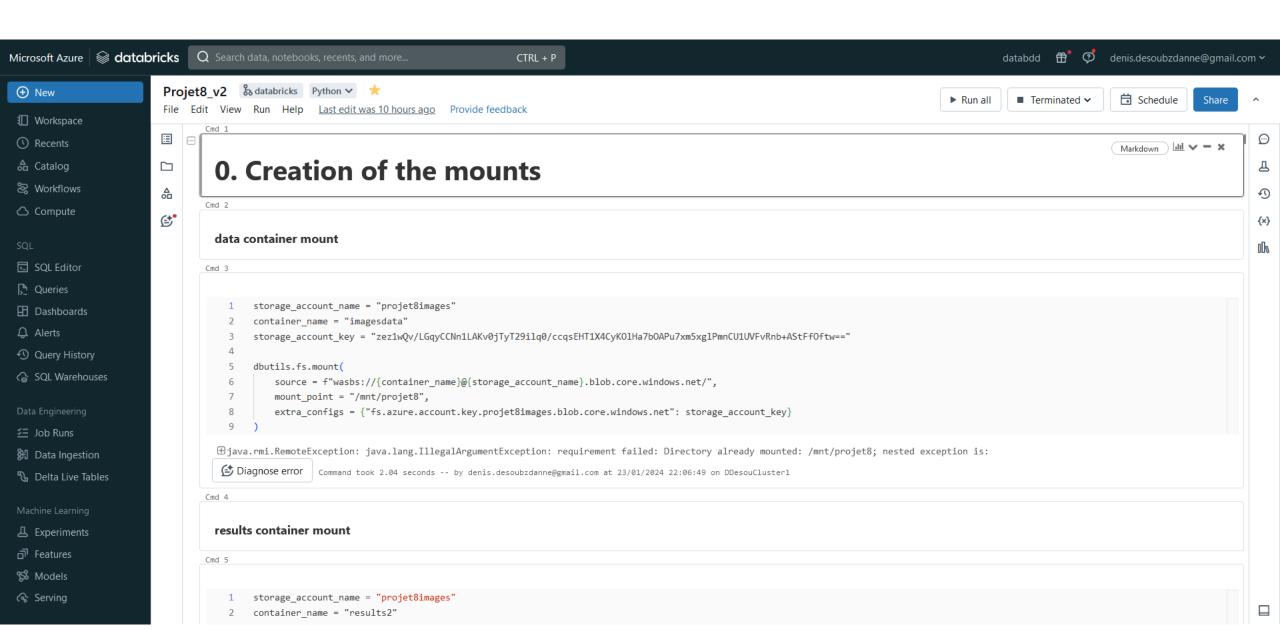
#### Démonstration de Databricks

Environnement de travail

Cluster

Notebook

#### Dashboard Databricks



# 06

#### Livrables & conclusion

Liens url Bilan

### Liens urls pour les différents livrables

- Lien vers notebook Databricks: <a href="https://adb-8983437898642533.13.azuredatabricks.net/browse/folde">https://adb-8983437898642533.13.azuredatabricks.net/browse/folde</a> rs/163836705254556?o=8983437898642533
- Lien pour télécharger la table csv de données pca :
   <u>https://projet8images.blob.core.windows.net/mytables/table.csv</u>
- Lien pour télécharger les images (fichier zip) :
   https://projet8images.blob.core.windows.net/zipfile/fruit
   s.zip
- Lien vers le repos GitHub : https://github.com/DDesou/Projet8.git

#### Conclusion

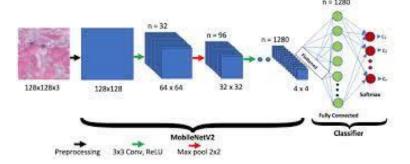
- Partie 1 : prise en main locale
  - Environnement Linux en local (WSL)



- Prise en main de Spark (Big Data)
- Extraction de features (transfer learning)



• Réduction de dimensions (ACP)



- Partie 2 : déploiement dans un environnement cloud
  - Microsoft Azure (compte et stockage)



• Databricks (plateforme d'analyse et d'exécution des tâches)









Denis Desoubzdanne

**31 Janvier 2024** 

Formation Data Scientist

